

MAKALAH MACHINE LEARNING
ANALISIS FAKTOR-FAKTOR YANG MEMPENGARUHI ATTRITION
KARYAWAN MENGGUNAKAN METODE KLASIFIKASI DENGAN
ALGORITMA LOGISTIC REGRESSION, RANDOM FOREST, DAN
XGBOOST MENGGUNAKAN PYTHON



Oleh:

- | | |
|---------------------------|-----------|
| 1. Fania Hasna Rasyida | K1D024001 |
| 2. Nabila Dwi Setiawati | K1D024005 |
| 3. Kinanti Jingga Adzhani | K1D024007 |
| 4. Amelia Wulandari | K1D024027 |
| 5. Hafdsa Syafiya | K1D024040 |

Disusun untuk memenuhi tugas terstruktur :

Mata kuliah : *Machine Learning*

Dosen : Lutfiah Maharani Siniwi S.Stat., M.Stat.

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO

2026

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga makalah yang berjudul “Analisis Faktor-Faktor yang Mempengaruhi *Attrition* Karyawan Menggunakan Metode Klasifikasi dengan Algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost* Menggunakan Python” dapat diselesaikan dengan baik.

Makalah ini disusun untuk memenuhi tugas mata kuliah serta sebagai sarana untuk menambah wawasan mengenai penerapan metode klasifikasi dalam bidang sumber daya manusia, khususnya dalam menganalisis faktor-faktor yang mempengaruhi *attrition* karyawan. Penelitian ini memanfaatkan algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost* untuk membangun model prediksi serta membandingkan kinerja masing-masing algoritma dalam mengidentifikasi karyawan yang berpotensi keluar dari perusahaan.

Dalam penyusunan makalah ini, penulis memperoleh bantuan, dukungan, dan masukan dari berbagai pihak. Oleh karena itu, penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah serta semua pihak yang telah memberikan dukungan selama proses penyusunan makalah ini.

Penulis menyadari bahwa makalah ini masih memiliki keterbatasan dan jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa yang akan datang.

Akhir kata, penulis berharap makalah ini dapat memberikan manfaat serta menambah pengetahuan bagi pembaca mengenai analisis data dan penerapan algoritma *machine learning* dalam memprediksi *attrition* karyawan.

Purwokerto, 20 Juni 2026

Penyusun

DAFTAR ISI

KATA PENGANTAR	i
DAFTAR ISI.....	ii
DAFTAR TABEL.....	iii
DAFTAR GAMBAR.....	iv
BAB I.....	1
PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan	2
1.4 Manfaat	3
BAB II.....	4
TINJAUAN DATASET.....	4
2.1 Human Resource Analytics.....	4
2.2 Employee Attrition.....	4
2.3 IBM HR Analytics Employee Attrition & Performance Dataset.....	5
2.4 Algoritma Logistic Regression	6
2.5 Algoritma Random Forest.....	6
2.6 Algoritma XGBoost	7
BAB III	8
METODELOGI	8
3.1 Sumber dan Teknik Pengumpulan Data.....	8
3.2 Variabel dan Definisi Operasional.....	8
3.3 Langkah-Langkah Analisis Data.....	13
BAB IV	16
HASIL DAN PEMBAHASAN.....	16
4.1 Analisis Deskriptif Dan Eksplorasi Data (Exploratory Data Analysis)	16
4.1.1 Statistika Deskriptif	16
4.1.2 Visualisasi	21
4.1.3 Identifikasi	28
4.1.4 Temuan Awal.....	32
4.2 Pra-Pemrosesan & Rekayasa Fitur.....	33
4.2.1 Penanganan <i>Missing Value</i>	33
4.2.2 Penanganan <i>Outlier</i>	33

4.2.3 <i>Encoding</i> Variabel Kategorik.....	34
4.2.4 <i>Scaling</i> Fitur Numerik.....	35
4.2.5 Standardisasi	36
4.2.6 <i>Feature Engineering</i>	36
4.2.7 <i>Train Test Split</i>	36
4.3 Pemodelan.....	37
4.3.1 Balance Data	37
4.3.2 Pemodelan.....	38
4.3.3 <i>Hyperparameter Tuning</i>	43
4.4 Evaluasi.....	45
BAB V	47
PENUTUP	47
5.1 Kesimpulan	47
5.2 Saran	48
LAMPIRAN.....	49

DAFTAR TABEL

Tabel 1. Variabel dan Definisi Operasional.....	9
Tabel 2. Hasil Statistika Deskriptif Variabel Numerik	16
Tabel 3. Hasil Statistika Deskriptif Variabel Kategorik	19
Tabel 4. Hasil Identifikasi Missing Value	28
Tabel 5. Hasil Identifikasi Duplikasi Data.....	30
Tabel 6. Encoding Variabel Kategorik	34
Tabel 7. Hasil Evaluasi Model Logistic Regression	39
Tabel 8. Hasil Evaluasi Model Random Forest	40
Tabel 9. Hasil Evaluasi Model Random Forest	42
Tabel 10. Hasil Evaluasi Model Hyperparameter Tuning Logistic Regression.....	43
Tabel 11. Hasil Evaluasi Semua Model.....	45

DAFTAR GAMBAR

Gambar 1. Visualisasi Pie Charts Variabel Kategorik	21
Gambar 2. Visualisasi Bar Charts Variabel Kategorik	22
Gambar 3. Visualisasi Heatmap Variabel Kategorik	23
Gambar 4. Visualisasi Histogram Variabel Numerik	24
Gambar 5. Visualisasi Boxplot Variabel Numerik	26
Gambar 6. Visualisasi Heatmap Korelasi antara Variabel Kategorik dan Numerik	27
Gambar 7. Distribusi Variabel Attrition	31
Gambar 8. Hasil SMOTE variabel Attrition	38
Gambar 9. Confusion Matrix Model Logistic Regression	39
Gambar 10. Confusion Matrix Model Random Forest	41
Gambar 11. Confusion Matrix Model Extreme Gradient Boosting (XGBoost)	43
Gambar 12. Confusion Matrix Model Hyperparameter Tuning Logistic Regression.....	44

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sumber daya manusia merupakan salah satu faktor utama dalam perusahaan yang berperan penting dalam mendukung pencapaian tujuan perusahaan. Keberhasilan perusahaan tidak hanya ditentukan oleh teknologi, modal, atau strategi bisnis yang digunakan, tetapi juga oleh kualitas dan stabilitas tenaga kerja yang dimiliki. Oleh karena itu, perusahaan perlu menjaga ketersediaan sumber daya manusia yang kompeten dan produktif. Salah satu tantangan yang sering dihadapi perusahaan dalam pengelolaan sumber daya manusia adalah tingginya tingkat *attrition* karyawan, yaitu kondisi ketika karyawan memutuskan untuk meninggalkan perusahaan secara sukarela maupun karena alasan tertentu. Tingginya angka *attrition* dapat menimbulkan berbagai dampak negatif, seperti meningkatnya biaya rekrutmen dan pelatihan karyawan baru, menurunnya produktivitas kerja, hilangnya pengetahuan dan pengalaman yang dimiliki karyawan, serta terganggunya stabilitas dan efektivitas operasional perusahaan.

Attrition karyawan dipengaruhi oleh berbagai faktor yang saling berkaitan, baik faktor individu maupun faktor yang berasal dari lingkungan kerja. Faktor-faktor tersebut dapat berupa usia, tingkat pendidikan, lama bekerja, tingkat pendapatan, lingkungan kerja, kepuasan kerja, peluang pengembangan karier, keseimbangan antara kehidupan pribadi dan pekerjaan, hingga jarak tempat tinggal ke lokasi kerja. Banyaknya faktor yang dapat mempengaruhi keputusan karyawan untuk keluar dari perusahaan membuat perusahaan perlu melakukan analisis yang lebih mendalam untuk memahami pola dan karakteristik *attrition* yang terjadi. Dengan mengetahui faktor-faktor yang berpengaruh, perusahaan dapat menyusun kebijakan yang lebih tepat dalam meningkatkan kepuasan dan loyalitas karyawan sehingga risiko terjadinya *attrition* dapat diminimalkan.

Seiring perkembangan teknologi informasi dan meningkatnya ketersediaan data dalam jumlah besar, metode *machine learning* dapat dimanfaatkan untuk membantu menganalisis dan memprediksi *attrition* karyawan secara lebih efektif. Salah satu pendekatan yang banyak digunakan adalah metode klasifikasi yang bertujuan mengelompokkan data ke dalam kategori tertentu berdasarkan karakteristik yang dimiliki. Dalam penelitian ini, digunakan tiga algoritma klasifikasi, yaitu *Logistic Regression*, *Random Forest*, dan *XGBoost*. *Logistic Regression* merupakan metode yang sederhana dan mudah diinterpretasikan untuk klasifikasi data biner, sedangkan *Random Forest* dan

XGBoost dikenal memiliki kemampuan yang baik dalam menangani data yang kompleks serta menghasilkan tingkat akurasi yang tinggi. Oleh karena itu, penelitian ini dilakukan untuk menganalisis faktor-faktor yang mempengaruhi *attrition* karyawan serta membandingkan kinerja algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost* dalam mengklasifikasikan status *attrition* karyawan sehingga dapat diperoleh model terbaik yang mampu mendukung pengambilan keputusan perusahaan dalam pengelolaan sumber daya manusia.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, permasalahan dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Faktor-faktor apa saja yang mempengaruhi *attrition* karyawan?
2. Bagaimana kinerja algoritma *Logistic Regression* dalam mengklasifikasikan *attrition* karyawan?
3. Bagaimana kinerja algoritma *Random Forest* dalam mengklasifikasikan *attrition* karyawan?
4. Bagaimana kinerja algoritma *XGBoost* dalam mengklasifikasikan *attrition* karyawan?
5. Algoritma manakah yang memberikan performa terbaik dalam mengklasifikasikan *attrition* karyawan?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah dirumuskan, berikut adalah tujuan penelitian yang akan dicapai:

1. Mengidentifikasi faktor-faktor yang mempengaruhi *attrition* karyawan.
2. Menganalisis kinerja algoritma *Logistic Regression* dalam mengklasifikasikan *attrition* karyawan.
3. Menganalisis kinerja algoritma *Random Forest* dalam mengklasifikasikan *attrition* karyawan.
4. Menganalisis kinerja algoritma *XGBoost* dalam mengklasifikasikan *attrition* karyawan.
5. Membandingkan performa algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost* untuk memperoleh model klasifikasi terbaik dalam memprediksi *attrition* karyawan.

1.4 Manfaat

Berdasarkan tujuan yang telah dirumuskan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Memberikan pemahaman mengenai faktor-faktor yang mempengaruhi *attrition* karyawan sehingga dapat membantu perusahaan dalam mengurangi tingkat *attrition*.
2. Memberikan pemahaman mengenai kinerja algoritma *Logistic Regression* dalam mengklasifikasikan *attrition* karyawan.
3. Memberikan pemahaman mengenai kinerja algoritma *Random Forest* dalam mengklasifikasikan *attrition* karyawan.
4. Memberikan pemahaman mengenai kinerja algoritma *XGBoost* dalam mengklasifikasikan *attrition* karyawan.
5. Memberikan rekomendasi model klasifikasi terbaik berdasarkan perbandingan performa algoritma *Logistic Regression*, *Random Forest*, dan *XGBoost* dalam memprediksi *attrition* karyawan.

BAB II

TINJAUAN DATASET

2.1 *Human Resource Analytics*

Human Resource Analytics (HR Analytics) merupakan pendekatan yang memanfaatkan data, statistik, dan teknologi analitik untuk mendukung pengambilan keputusan dalam bidang sumber daya manusia. HR Analytics memungkinkan organisasi untuk mengubah data karyawan menjadi informasi yang bernilai sehingga keputusan yang diambil tidak hanya berdasarkan intuisi, tetapi juga didukung oleh bukti empiris dan hasil analisis data (Marler & Boudreau, 2017). Pendekatan ini menjadi semakin penting seiring meningkatnya ketersediaan data karyawan dan perkembangan teknologi analisis data.

HR Analytics dapat diterapkan pada berbagai aspek pengelolaan sumber daya manusia, seperti rekrutmen, evaluasi kinerja, pengembangan karier, perencanaan tenaga kerja, hingga analisis attrition. Salah satu penerapan yang paling banyak dilakukan adalah prediksi attrition karyawan karena berkaitan langsung dengan keberlangsungan organisasi. Melalui analisis data historis, perusahaan dapat mengidentifikasi karakteristik karyawan yang memiliki kecenderungan untuk meninggalkan perusahaan sehingga tindakan pencegahan dapat dilakukan lebih awal (Fitz-enz & Mattox, 2014).

Perkembangan metode *machine learning* semakin memperluas pemanfaatan HR Analytics. Berbagai algoritma klasifikasi seperti *Logistic Regression*, *Decision Tree*, *Random Forest*, dan *Support Vector Machine* telah digunakan untuk memprediksi attrition karyawan dengan tingkat akurasi yang cukup baik (Kelleher et al., 2020). Hasil prediksi tersebut dapat membantu organisasi dalam merancang kebijakan retensi, meningkatkan kepuasan kerja, dan mengurangi risiko kehilangan tenaga kerja yang berpotensi memberikan kontribusi besar bagi perusahaan.

Dengan demikian, HR Analytics tidak hanya berfungsi sebagai alat untuk memahami kondisi sumber daya manusia saat ini, tetapi juga sebagai sarana untuk memprediksi kondisi yang mungkin terjadi di masa mendatang. Pendekatan ini mendukung penerapan data *driven decision making* yang semakin banyak digunakan dalam organisasi modern (Marler & Boudreau, 2017).

2.2 *Employee Attrition*

Employee attrition merupakan kondisi ketika seorang karyawan meninggalkan organisasi sehingga jumlah tenaga kerja dalam perusahaan berkurang. Attrition dapat

terjadi secara sukarela (*voluntary attrition*), yaitu ketika karyawan memutuskan untuk mengundurkan diri atas keinginannya sendiri, maupun secara tidak sukarela (*involuntary attrition*) akibat keputusan perusahaan atau faktor lainnya (Dessler, 2020). Fenomena ini menjadi perhatian penting dalam manajemen sumber daya manusia karena dapat mempengaruhi produktivitas, stabilitas organisasi, serta biaya operasional perusahaan.

Tingginya tingkat attrition sering kali menyebabkan perusahaan harus mengeluarkan biaya tambahan untuk proses rekrutmen, pelatihan, dan adaptasi karyawan baru. Selain itu, pergantian tenaga kerja yang tinggi dapat mengurangi efektivitas organisasi dan menurunkan kualitas layanan yang diberikan kepada pelanggan (Mathis et al., 2017).

Dalam beberapa tahun terakhir, *attrition* menjadi salah satu topik yang banyak diteliti dalam bidang analisis sumber daya manusia. Hal ini disebabkan oleh pentingnya mempertahankan tenaga kerja yang memiliki pengalaman dan kompetensi tinggi. Kehilangan karyawan berpengalaman tidak hanya berdampak pada biaya organisasi, tetapi juga dapat menyebabkan hilangnya pengetahuan dan keterampilan yang telah terbentuk selama masa kerja karyawan tersebut (Dessler, 2020).

Berbagai faktor diketahui berhubungan dengan attrition karyawan, seperti usia, tingkat pendapatan, kepuasan kerja, lingkungan kerja, masa kerja, serta keseimbangan antara kehidupan pribadi dan pekerjaan. Dengan memanfaatkan data historis karyawan, perusahaan dapat mengidentifikasi pola-pola yang berkaitan dengan keputusan karyawan untuk meninggalkan perusahaan sehingga dapat menyusun strategi retensi yang lebih efektif (Fitz-enz & Mattox, 2014).

2.3 IBM HR Analytics Employee Attrition & Performance Dataset

Dataset yang digunakan dalam penelitian ini adalah IBM HR *Analytics Employee Attrition & Performance* Dataset. Dataset ini merupakan dataset simulasi (*fictional dataset*) yang dikembangkan oleh ilmuwan data IBM untuk tujuan pembelajaran dan analisis dalam bidang *Human Resource Analytics* (IBM, 2016). Dataset tersebut dirancang untuk membantu pengguna mengeksplorasi faktor-faktor yang memengaruhi attrition karyawan serta menjawab berbagai pertanyaan analitis yang berkaitan dengan karakteristik tenaga kerja.

IBM HR *Analytics Employee Attrition & Performance* Dataset menjadi salah satu dataset yang paling populer dalam penelitian prediksi attrition karena menyediakan informasi yang cukup lengkap mengenai kondisi demografis, pekerjaan, kompensasi, dan tingkat kepuasan karyawan. Dataset ini memungkinkan peneliti untuk menganalisis

hubungan antara berbagai faktor yang dimiliki karyawan dengan status attrition yang menjadi variabel target dalam penelitian (IBM, 2016).

Karena memiliki struktur data yang lengkap dan mudah diakses, dataset ini telah banyak digunakan sebagai benchmark dataset dalam penelitian statistik, data mining, dan *machine learning* yang berkaitan dengan prediksi *attrition* karyawan. Berbagai penelitian menggunakan dataset ini untuk mengidentifikasi faktor-faktor yang paling berpengaruh terhadap keputusan karyawan untuk meninggalkan perusahaan serta membangun model prediksi yang dapat membantu pengambilan keputusan dalam bidang sumber daya manusia (Mishra et al., 2021).

2.4 Algoritma Logistic Regression

Logistic Regression merupakan salah satu metode klasifikasi yang digunakan untuk memprediksi probabilitas suatu kejadian berdasarkan variabel independen yang tersedia. Berbeda dengan regresi linear yang menghasilkan nilai kontinu, *Logistic Regression* menghasilkan nilai probabilitas yang kemudian diklasifikasikan ke dalam kelas tertentu menggunakan fungsi logistik atau sigmoid (Hosmer et al., 2013).

Metode ini banyak digunakan karena sederhana, mudah diinterpretasikan, dan efektif untuk permasalahan klasifikasi biner maupun multi kelas. Selain itu, *Logistic Regression* mampu menunjukkan pengaruh masing-masing variabel prediktor terhadap peluang terjadinya suatu kejadian melalui koefisien model yang dihasilkan. Oleh karena itu, algoritma ini sering digunakan sebagai model dasar (*baseline model*) dalam berbagai penelitian machine learning dan data mining (James et al., 2021).

2.5 Algoritma Random Forest

Random Forest merupakan algoritma machine learning yang termasuk dalam metode *ensemble learning*. Algoritma ini bekerja dengan membangun sejumlah pohon keputusan (*decision tree*) dari sampel data yang berbeda menggunakan teknik *bootstrap aggregating* (*bagging*) (Breiman, 2001).

Setiap pohon memberikan hasil prediksi, kemudian hasil akhir ditentukan berdasarkan suara mayoritas pada kasus klasifikasi atau rata-rata pada kasus regresi. Penggunaan banyak pohon keputusan membuat Random Forest lebih stabil dan mampu mengurangi risiko *overfitting* dibandingkan satu pohon keputusan tunggal. Selain itu, algoritma ini dapat menangani data berukuran besar serta mampu mengukur tingkat kepentingan

variabel (*feature importance*) yang berguna dalam proses interpretasi model (Breiman, 2001; Géron, 2022).

2.6 Algoritma XGBoost

Extreme Gradient Boosting (XGBoost) merupakan pengembangan dari metode Gradient Boosting yang dirancang untuk meningkatkan kecepatan komputasi dan akurasi prediksi. Algoritma ini membangun model secara bertahap dengan memperbaiki kesalahan model sebelumnya pada setiap iterasi (Chen & Guestrin, 2016).

XGBoost menggunakan teknik regularisasi untuk mengurangi *overfitting* serta mendukung pemrosesan paralel sehingga lebih efisien dalam menangani data berukuran besar. Selain itu, algoritma ini memiliki kemampuan menangani data yang kompleks dan sering menghasilkan performa prediksi yang lebih baik dibandingkan metode klasifikasi lainnya. Karena keunggulan tersebut, XGBoost banyak digunakan dalam berbagai kompetisi data science dan penelitian yang berkaitan dengan klasifikasi maupun prediksi (Chen & Guestrin, 2016).

BAB III

METODELOGI

3.1 Sumber dan Teknik Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang diperoleh dari dataset IBM HR *Analytics Employee Attrition & Performance* yang tersedia secara publik melalui platform Kaggle. Dataset ini merupakan data fiktif yang dikembangkan oleh ilmuwan data IBM untuk keperluan analisis sumber daya manusia, khususnya dalam mengidentifikasi faktor-faktor yang memengaruhi tingkat *employee attrition* (keluar atau berpindahnya karyawan dari perusahaan). Dataset tersebut banyak digunakan dalam penelitian dan pembelajaran terkait analisis data, data mining, serta machine learning di bidang manajemen sumber daya manusia.

Dataset IBM HR *Analytics Employee Attrition & Performance* terdiri atas 1.470 observasi yang merepresentasikan karyawan dan 35 variabel yang mencakup karakteristik demografi, kondisi pekerjaan, kepuasan kerja, pendapatan, pengalaman kerja, serta status attrition karyawan. Variabel-variabel tersebut meliputi antara lain usia (*Age*), jenis kelamin (*Gender*), status pernikahan (*Marital Status*), tingkat pendidikan (*Education*), pendapatan bulanan (*Monthly Income*), kepuasan kerja (*Job Satisfaction*), keseimbangan kehidupan dan pekerjaan (*Work-Life Balance*), serta status attrition (*Attrition*) sebagai variabel utama yang diamati.

Teknik pengumpulan data dalam penelitian ini dilakukan melalui dokumentasi, yaitu dengan mengunduh dan mengakses database yang telah tersedia pada platform Kaggle. Karena data yang digunakan merupakan data sekunder yang telah dipublikasikan, penelitian ini tidak melibatkan pengumpulan data secara langsung melalui survei, wawancara, maupun eksperimen. Selanjutnya, data yang diperoleh diolah dan dianalisis menggunakan perangkat lunak statistik sesuai dengan tujuan penelitian.

3.2 Variabel dan Definisi Operasional

Variabel dalam penelitian ini terdiri atas variabel terikat (*target variable*) dan variabel bebas (*predictor variables*) yang digunakan dalam pembangunan model klasifikasi untuk memprediksi kemungkinan terjadinya *employee attrition*. Variabel terikat dalam penelitian ini adalah Attrition, sedangkan variabel bebas merupakan karakteristik demografi, pekerjaan, pendapatan, dan tingkat kepuasan karyawan yang terdapat dalam dataset IBM

HR Analytics Employee Attrition & Performance. Definisi operasional variabel yang digunakan dalam penelitian ini disajikan pada Tabel 1.

Tabel 1. Variabel dan Definisi Operasional

No	Variabel	Jenis Variabel	Definisi	Kategori/Kode	Skala
1.	Attrition	Terikat	Status keluar atau tetap bekerja	Yes = Keluar, No = Tetap bekerja	Nominal
2.	Age	Bebas	Usia Karyawan	Tahun	Rasio
3.	BusinessTravel	Bebas	Frekuensi perjalanan dinas	Non-Travel, Travel Rarely, Travel Frequently	Nominal
4.	DailyRate	Bebas	Tarif pendapatan harian	Nilai Numerik	Rasio
5.	Departement	Bebas	Departemen tempat bekerja	Human Resource, Research & Development, Sales	Nominal
6.	DistanceFromHome	Bebas	Jarak rumah ke tempat kerja	Kilometer	Rasio
7.	Education	Bebas	Tingkat pendidikan karyawan	1-5	Ordinal
8.	EducationField	Bebas	Bidang	Sesuai kategori	Nominal

			pendidikan terakhir		
9.	EmployeeNumber	Bebas	Nomor identitas karyawan	Jumlah karyawan	Nilai numerik
10.	EnvironmentSatisfaction	Bebas	Tingkat kepuasan	1-4	Ordinal
11.	Gender	Bebas	Jenis kelamin karyawan	Male, Female	Nominal
12.	HourlyRate	Bebas	Tarif pendapatan per jam	1-4	Ordinal
13.	EmployeeCount	Bebas	Jumlah karyawan	Nilai numerik	Nominal
14.	JobInvolvement	Bebas	Tingkat keterlibatan dalam pekerjaan	1-4	ordinal
15.	JobLevel	Bebas	Tingkat jabatan	1-5	Ordinal
16.	JobRole	Bebas	Posisi atau jabatan karyawan	Sesuai kategori jabatan	Nominal
17.	JobSatisfaction	Bebas	Tingkat kepuasan kerja	1-4	Ordinal

18.	MaritalStatus	Bebas	Status pernikahan	Single, Married, Divorce	Nominal
19.	MonthlyIncome	Bebas	Pendapatan bukannya	Nilai numerik	Rasio
20.	MonthlyRate	Bebas	Tarif pendapatan bulanan	Nilai numerik	Rasio
21.	NumCompanies Worked	Bebas	Jumlah perusahaan yang pernah menjadi tempat bekerja	Nilai numerik	Rasio
22.	Over18	Bebas	Status usia di atas 18 tahun	Nilai numerik	Rasio
23.	OverTime	Bebas	Status lembur	Y	Nominal
24.	PrecentSalaryHike	Bebas	Persenta kenaikan gaji	Presentase (%)	Rasio
25.	PerformanceRating	Bebas	Penilaian kerja	1-4	Ordinal
26.	RelationshipSatisfaction	Bebas	Tingkat kepuasan hubungan kerja	1-4	Ordinal
27.	StandardHours	Bebas	Jam kerja	Jam	Rasio

			standar		
28.	StockOptimalLevel	Bebas	Tingkat kepemilikan opsi saham	0-3	Ordinal
29.	TotalWorkingYears	Bebas	Total pengalaman kerja	Tahun	Rasio
30.	TrainingTimesLastYear	Bebas	Jumlah pelatihan yang diikuti tahun lalu	Frekuensi	Rasio
31.	WorkLifeBalance	Bebas	Tingkat keseimbangan kerja dan kehidupan pribadi	1-4	Ordinal
32.	YearsAtCompany	Bebas	Lama bekerja di perusahaan saat ini	Tahun	Rasio
33.	YearsinCurrentRole	Bebas	Lama bekerja pada posisi saat ini	Tahun	Rasio
34.	YearSinceLastPromotion	Bebas	Lama sejak promosi terakhir	Tahun	Rasio
35.	YearsWithCurr	Bebas	Lama	Tahun	Rasio

	Manager		bekerja dengan manajer saat ini		
--	---------	--	--	--	--

3.3 Langkah-Langkah Analisis Data

Analisis data pada penelitian ini dilakukan menggunakan bahasa pemrograman Python melalui platform Google *Collaboratory* (Google Colab). Metode yang digunakan adalah machine learning dengan pendekatan klasifikasi untuk memprediksi kemungkinan terjadinya *employee attrition* pada karyawan. Tahapan analisis data yang dilakukan adalah sebagai berikut.

1. Business Understanding

Tahap pertama dilakukan dengan memahami permasalahan bisnis yang berkaitan dengan tingginya tingkat *employee attrition* dalam perusahaan. Tujuan penelitian adalah membangun model klasifikasi yang mampu memprediksi apakah seorang karyawan berpotensi keluar dari perusahaan (*Attrition = Yes*) atau tetap bekerja (*Attrition = No*) berdasarkan karakteristik demografi, pekerjaan, pendapatan, dan tingkat kepuasan kerja yang dimiliki.

2. Data Understanding

Tahap ini bertujuan untuk memahami karakteristik dataset IBM HR *Analytics Employee Attrition & Performance* yang digunakan dalam penelitian. Kegiatan yang dilakukan meliputi:

- Mengunggah dan membaca dataset ke dalam lingkungan Google Colab menggunakan *library Python*.
- Mengidentifikasi variabel numerik dan kategorikal yang terdapat dalam dataset.
- Menampilkan informasi dataset untuk mengetahui tipe data, jumlah observasi, dan jumlah variabel.
- Melakukan analisis statistik deskriptif untuk memperoleh gambaran umum data seperti nilai minimum, maksimum, rata-rata, dan standar deviasi.
- Melakukan visualisasi distribusi data menggunakan histogram untuk variabel numerik dan diagram batang atau diagram lingkaran untuk variabel kategorikal.
- Menganalisis hubungan antar variabel menggunakan matriks korelasi dan heatmap untuk mengetahui tingkat hubungan antar fitur.

3. Data *Preprocessing*

Tahap *preprocessing* dilakukan untuk meningkatkan kualitas data sebelum digunakan dalam pemodelan machine learning. Tahapan yang dilakukan meliputi:

a. Penanganan *Missing Value*

Dilakukan identifikasi terhadap data yang hilang pada setiap variabel. Jika ditemukan *missing value*, maka dilakukan imputasi menggunakan metode yang sesuai, seperti mean atau median untuk variabel numerik dan modus untuk variabel kategorikal.

b. Penanganan *Outlier*

Deteksi outlier dilakukan menggunakan metode Interquartile Range (IQR). Nilai yang berada di luar batas normal ditangani menggunakan teknik *capping* sehingga tidak memberikan pengaruh berlebihan terhadap model.

c. Encoding Variabel Kategorikal

Variabel kategorikal seperti *Gender*, *Department*, *JobRole*, *BusinessTravel*, *MaritalStatus*, dan variabel kategorikal lainnya diubah menjadi bentuk numerik menggunakan teknik Label Encoding atau *One-Hot Encoding* sesuai karakteristik variabel.

d. Normalisasi Data

Variabel numerik seperti *Age*, *MonthlyIncome*, *DistanceFromHome*, *YearsAtCompany*, dan variabel numerik lainnya dinormalisasi menggunakan metode Min-Max Scaling agar memiliki rentang nilai yang seragam.

e. Deteksi Data Duplikat

Dilakukan pemeriksaan data duplikat untuk memastikan tidak terdapat observasi yang berulang dalam dataset.

4. Data *Construction*

Tahap konstruksi data dilakukan untuk menghasilkan dataset yang optimal sebelum proses pemodelan.

a. *Feature Engineering*

Pada tahap ini dilakukan transformasi dan penyesuaian variabel yang dianggap dapat meningkatkan performa model klasifikasi.

b. *Feature Selection*

Seleksi fitur dilakukan menggunakan *Logistic Regression* untuk mengidentifikasi variabel yang memiliki kontribusi paling besar terhadap prediksi

employee attrition. Hanya fitur-fitur yang memiliki pengaruh signifikan yang digunakan pada tahap pemodelan.

c. *Pembagian Data*

Dataset dibagi menjadi data pelatihan (*training data*) sebesar 80% dan data pengujian (*testing data*) sebesar 20%. Pembagian dilakukan menggunakan metode stratified sampling agar proporsi kelas pada variabel target tetap terjaga.

5. *Modeling*

Pada tahap ini dilakukan pembangunan model machine learning untuk memprediksi *employee attrition*.

a. *Logistic Regression*

Model *Logistic Regression* digunakan sebagai model klasifikasi dasar untuk memprediksi status attrition karyawan. Optimasi parameter dilakukan menggunakan *Grid Search Cross Validation* untuk memperoleh kombinasi parameter terbaik.

b. *XGBoost Classifier*

Model XGBoost digunakan sebagai metode klasifikasi berbasis boosting yang mampu menangani hubungan nonlinier antarvariabel. Hyperparameter tuning dilakukan menggunakan *Grid Search Cross Validation* untuk meningkatkan performa model.

6. *Evaluation*

Tahap evaluasi dilakukan untuk mengukur kinerja model yang telah dibangun.

a. *Pengukuran Kinerja Model*

Kinerja model dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan ROC-AUC.

b. *Confusion Matrix*

Confusion Matrix digunakan untuk mengetahui jumlah prediksi yang benar dan salah pada masing-masing kelas, yaitu karyawan yang keluar (*Attrition = Yes*) dan karyawan yang tetap bekerja (*Attrition = No*).

c. *Learning Curve*

Learning Curve digunakan untuk mengevaluasi kemampuan generalisasi model serta mendeteksi kemungkinan terjadinya *overfitting* atau *underfitting*.

d. *Perbandingan Model*

Performa model *Logistic Regression* dan *XGBoost* dibandingkan berdasarkan nilai *F1-Score* dan ROC-AUC. Model dengan performa terbaik dipilih sebagai model akhir untuk memprediksi kemungkinan terjadinya *employee attrition* pada karyawan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Analisis Deskriptif Dan Eksplorasi Data (*Exploratory Data Analysis*)

4.1.1 Statistika Deskriptif

Analisis statistik deskriptif dilakukan untuk memberikan gambaran umum mengenai karakteristik data yang digunakan dalam penelitian. Statistik deskriptif menyajikan informasi mengenai ukuran pemusatan data dan ukuran penyebaran data, seperti nilai rata-rata (mean), standar deviasi, nilai minimum, nilai maksimum, serta nilai kuartil. Melalui analisis ini, peneliti dapat memahami distribusi data dan karakteristik masing-masing variabel yang diteliti sebelum melakukan analisis lebih lanjut.

Pada penelitian ini, statistik deskriptif dihitung terhadap seluruh variabel numerik yang terdapat dalam dataset dengan jumlah observasi sebanyak 1.470 data karyawan. Hasil statistik deskriptif digunakan untuk mengetahui kecenderungan nilai setiap variabel, tingkat variasi data, serta rentang nilai yang dimiliki oleh masing-masing variabel. Informasi tersebut penting sebagai dasar dalam melakukan analisis lanjutan dan interpretasi hasil penelitian.

Tabel 2. Hasil Statistika Deskriptif Variabel Numerik

Variabel	Mean	Std. Deviasi	Min	Max
Age	36.92	9.14	18	60
DailyRate	802.49	403.51	102	1499
DistanceFromHome	9.19	8.11	1	29
Education	2.91	1.02	1	5
EmployeeCount	1.00	0.00	1	1

EmployeeNumber	1024.87	602.02	1	2068
EnvironmentSatisfaction	2.72	1.09	1	4
HourlyRate	65.89	20.33	30	100
JobInvolvement	2.73	0.71	1	4
JobLevel	2.06	1.11	1	5
RelationshipSatisfaction	2.71	1.08	1	4
StandardHours	80.00	0.00	80	80
StockOptionLevel	0.79	0.85	0	3
TotalWorkingYears	11.28	7.78	0	40
TrainingTimesLastYear	2.80	1.29	0	6
WorkLifeBalance	2.76	0.71	1	4
YearsAtCompany	7.01	6.13	0	40
YearsInCurrentRole	4.23	3.62	0	18

YearsSinceLastPromotion	2.19	3.22	0	15
YearsWithCurrManager	4.12	3.57	0	17

Berdasarkan hasil analisis statistik deskriptif terhadap 1.470 data karyawan, diperoleh gambaran umum mengenai karakteristik responden dan variabel penelitian. Statistik deskriptif yang digunakan meliputi nilai rata-rata (mean), standar deviasi, nilai minimum, kuartil, median, dan nilai maksimum.

Variabel *Age* menunjukkan bahwa rata-rata usia karyawan adalah 36,92 tahun dengan standar deviasi sebesar 9,14 tahun. Usia termuda dalam dataset adalah 18 tahun dan usia tertua adalah 60 tahun. Nilai median sebesar 36 tahun menunjukkan bahwa sebagian besar karyawan berada pada rentang usia produktif. Berdasarkan nilai kuartil, 50% karyawan memiliki usia antara 30 hingga 43 tahun.

Variabel *Daily Rate* memiliki rata-rata sebesar 802,49 dengan standar deviasi sebesar 403,51. Nilai minimum yang tercatat adalah 102 dan nilai maksimum sebesar 1.499. Besarnya standar deviasi menunjukkan adanya variasi yang cukup tinggi pada nilai *DailyRate* antar karyawan.

Untuk variabel *Distance From Home*, diperoleh rata-rata sebesar 9,19 dengan standar deviasi 8,11. Nilai minimum dan maksimum masing-masing adalah 1 dan 29. Hal ini menunjukkan bahwa jarak tempat tinggal karyawan terhadap lokasi kerja cukup bervariasi, dengan median sebesar 7 yang mengindikasikan bahwa sebagian besar karyawan tinggal relatif dekat dengan tempat kerja.

Variabel *Education* memiliki rata-rata sebesar 2,91 pada skala 1 hingga 5, dengan standar deviasi sebesar 1,02. Nilai median sebesar 3 menunjukkan bahwa tingkat pendidikan karyawan secara umum berada pada kategori menengah.

Pada variabel *Environment Satisfaction*, diperoleh rata-rata sebesar 2,72 dengan standar deviasi 1,09. Hasil ini menunjukkan bahwa tingkat kepuasan karyawan terhadap lingkungan kerja cenderung berada pada kategori sedang. Demikian pula, variabel *Job Involvement* memiliki rata-rata sebesar 2,73 yang menunjukkan tingkat keterlibatan karyawan dalam pekerjaan berada pada tingkat sedang hingga tinggi.

Variabel *Total Working Years* menunjukkan rata-rata pengalaman kerja karyawan sebesar 11,28 tahun dengan standar deviasi sebesar 7,78 tahun. Nilai minimum adalah 0 tahun dan maksimum mencapai 40 tahun. Besarnya variasi data menunjukkan bahwa perusahaan memiliki karyawan dengan tingkat pengalaman yang sangat beragam, mulai dari karyawan baru hingga karyawan yang telah berpengalaman puluhan tahun.

Selanjutnya, variabel *Years At Company* memiliki rata-rata sebesar 7,01 tahun dengan standar deviasi sebesar 6,13 tahun. Nilai median sebesar 5 tahun menunjukkan bahwa sebagian besar karyawan telah bekerja di perusahaan selama periode yang cukup lama. Sementara itu, nilai maksimum sebesar 40 tahun mengindikasikan adanya karyawan yang telah mengabdikan diri dalam jangka waktu yang sangat panjang.

Variabel *Work Life Balance* memiliki rata-rata sebesar 2,76 pada skala 1 hingga 4 dengan standar deviasi sebesar 0,71. Hasil ini menunjukkan bahwa secara umum karyawan menilai keseimbangan antara kehidupan pribadi dan pekerjaan berada pada kategori cukup baik. Selain itu, terdapat beberapa variabel yang memiliki nilai standar deviasi sebesar nol, yaitu *Employee Count* dan *Standard Hours*. Kondisi ini menunjukkan bahwa seluruh observasi memiliki nilai yang sama pada kedua variabel tersebut, sehingga variabel tersebut tidak memberikan informasi yang dapat digunakan untuk membedakan karakteristik antar karyawan dan umumnya tidak digunakan dalam analisis lanjutan.

Secara keseluruhan, hasil statistik deskriptif menunjukkan bahwa mayoritas karyawan berada pada usia produktif, memiliki pengalaman kerja yang cukup baik, serta menunjukkan tingkat kepuasan dan keseimbangan kerja yang relatif positif. Variasi yang cukup besar pada beberapa variabel, seperti pengalaman kerja dan masa kerja di perusahaan, mengindikasikan adanya keragaman karakteristik sumber daya manusia dalam organisasi yang diteliti.

Selain analisis deskriptif untuk variabel numerik, analisis statistik deskriptif juga perlu dilakukan untuk variabel kategorik dilakukan untuk mengetahui jumlah kategori yang dimiliki setiap variabel, kategori yang paling dominan, serta frekuensi kemunculannya dalam dataset.

Tabel 3. Hasil Statistika Deskriptif Variabel Kategorik

Variabel	Count	Unique	Top	Freq
Attrition	1470	2	No	1233

BusinessTravel	1470	3	Travel_Rarely	1043
Department	1470	3	Research & Development	961
EducationField	1470	6	Life Sciences	606
Gender	1470	2	Male	882
JobRole	1470	9	Sales Executive	326
MaritalStatus	1470	3	Married	673
Over18	1470	1	Y	1470
OverTime	1470	2	No	1054

Berdasarkan Tabel 3, diketahui bahwa variabel *Attrition* memiliki dua kategori, yaitu karyawan yang keluar dan tidak keluar dari perusahaan. Kategori yang paling dominan adalah *No* dengan frekuensi sebanyak 1.233 karyawan, yang menunjukkan bahwa sebagian besar karyawan masih bekerja di perusahaan.

Pada variabel Business Travel, kategori yang paling banyak muncul adalah *Travel Rarely* dengan frekuensi 1.043 karyawan. Hal ini menunjukkan bahwa mayoritas karyawan hanya melakukan perjalanan dinas dalam intensitas yang relatif jarang.

Variabel Department didominasi oleh departemen *Research & Development* dengan jumlah 961 karyawan, sedangkan pada variabel Education Field, kategori *Life Sciences* merupakan bidang pendidikan yang paling banyak dimiliki oleh karyawan dengan frekuensi 606 orang.

Berdasarkan variabel Gender, jumlah karyawan laki-laki lebih dominan dibandingkan perempuan, yaitu sebanyak 882 karyawan. Sementara itu, pada variabel *Job Role*, posisi


Sales Executive merupakan jabatan yang paling banyak ditempati dengan frekuensi 326 karyawan.

Untuk variabel Marital Status, kategori *Married* menjadi kategori yang paling dominan dengan jumlah 673 karyawan. Selanjutnya, seluruh karyawan memiliki nilai yang sama pada variabel *Over 18*, yaitu kategori *Y*, sehingga variabel ini tidak memiliki variasi data. Pada variabel *Over Time*, mayoritas karyawan tidak melakukan lembur (*No*) dengan frekuensi sebanyak 1.054 karyawan.

Secara keseluruhan, hasil statistik deskriptif variabel kategorik menunjukkan bahwa sebagian besar karyawan berada pada departemen *Research & Development*, memiliki latar belakang pendidikan *Life Sciences*, berjenis kelamin laki-laki, berstatus menikah, dan tidak melakukan lembur. Temuan ini memberikan gambaran umum mengenai karakteristik responden yang menjadi objek penelitian.


4.1.2 Visualisasi

- Variabel Kategorik




Gambar 1. Visualisasi Pie Charts Variabel Kategorik

Berdasarkan Gambar 1. Visualisasi Pie Charts Variabel Kategorik, terlihat bahwa sebagian besar karyawan tidak mengalami attrition (83,9%), sedangkan karyawan yang mengalami attrition hanya sebesar 16,1%. Hal ini mengindikasikan bahwa data memiliki distribusi kelas yang tidak seimbang dengan dominasi kategori non-attrition. Mayoritas karyawan berasal dari departemen Research & Development (65,4%), berjenis kelamin laki-laki (60,0%), berstatus menikah (45,8%), serta memiliki tingkat pendidikan kategori 3 (38,9%). Selain itu, sebagian besar karyawan jarang melakukan perjalanan dinas (Travel_Rarely sebesar 71,0%) dan tidak melakukan lembur (71,7%). Dari aspek pekerjaan, mayoritas karyawan berada pada Job Level 1 dan 2, memiliki tingkat keterlibatan kerja (Job Involvement) kategori 3 sebesar 59,0%, serta memperoleh Performance Rating kategori 3 sebesar 84,6%. Tingkat kepuasan karyawan juga cenderung berada pada kategori menengah hingga tinggi, yang terlihat dari dominasi kategori 3 dan 4 pada variabel Environment Satisfaction, Job Satisfaction, Relationship Satisfaction, dan Work-Life Balance. Selain itu, bidang pendidikan yang paling banyak dimiliki karyawan adalah Life Sciences (41,2%) dan Medical (31,6%). Secara umum, karakteristik data menunjukkan bahwa mayoritas karyawan memiliki tingkat kepuasan dan keterlibatan kerja yang cukup baik, berada pada level jabatan awal hingga menengah, serta memiliki keseimbangan kehidupan dan pekerjaan yang relatif baik.



Gambar 2. Visualisasi Bar Charts Variabel Kategorik


Berdasarkan Gambar 2. Visualisasi Bar Charts Variabel Kategorik, terlihat bahwa posisi Sales Executive memiliki jumlah karyawan terbanyak, diikuti oleh Research Scientist dan Laboratory Technician. Sebaliknya, posisi Human Resources memiliki jumlah karyawan paling sedikit dibandingkan posisi lainnya. Selain itu, jumlah karyawan pada posisi Manufacturing Director, Healthcare Representative, Manager, Sales Representative, dan Research Director berada pada tingkat yang relatif lebih rendah dibandingkan tiga posisi yang dominan. Kondisi ini menunjukkan bahwa struktur tenaga kerja dalam dataset didominasi oleh posisi yang berkaitan dengan kegiatan penjualan, penelitian, dan operasional laboratorium, sedangkan posisi manajemen dan sumber daya manusia memiliki proporsi yang lebih kecil. Perbedaan distribusi antarposisi tersebut mengindikasikan adanya variasi komposisi jabatan yang berpotensi memengaruhi tingkat attrition karyawan pada masing-masing kelompok pekerjaan.



Gambar 3. Visualisasi Heatmap Variabel Kategorik


Berdasarkan Gambar 3. Visualisasi Heatmap Variabel Kategorik, terlihat bahwa sebagian besar pasangan variabel memiliki nilai Cramer's V yang rendah, sehingga menunjukkan hubungan yang lemah antarvariabel. Hubungan yang paling kuat terdapat antara Department dan JobRole dengan nilai sebesar 0,94, diikuti oleh Department dan EducationField sebesar 0,59, MaritalStatus dan StockOptionLevel sebesar 0,58, serta JobLevel dan JobRole sebesar 0,57. Sementara itu, terhadap variabel Attrition, nilai hubungan tertinggi ditunjukkan oleh JobRole dan OverTime yang masing-masing memiliki nilai Cramer's V sebesar 0,24, diikuti JobLevel sebesar 0,22 dan StockOptionLevel sebesar 0,20. Hasil ini menunjukkan bahwa tidak terdapat variabel kategorik yang memiliki hubungan sangat kuat dengan Attrition, sehingga kemungkinan attrition karyawan dipengaruhi oleh kombinasi beberapa faktor, bukan hanya satu faktor tertentu.


- Variabel Numerik



Gambar 4. Visualisasi Histogram Variabel Numerik


Berdasarkan Gambar 4. Visualisasi Histogram Distribusi Variabel Numerik, terlihat bahwa setiap variabel memiliki pola sebaran yang berbeda. Variabel Age cenderung mendekati distribusi normal dengan konsentrasi data pada usia 30–40 tahun. Variabel DailyRate, HourlyRate, EmployeeNumber, dan MonthlyRate menunjukkan distribusi yang relatif merata di seluruh rentang nilainya. Sementara itu, variabel DistanceFromHome, MonthlyIncome, NumCompaniesWorked, PercentSalaryHike, TotalWorkingYears, YearsAtCompany, YearsInCurrentRole, YearsSinceLastPromotion, dan YearsWithCurrManager cenderung menceng ke kanan (*right-skewed*), ditandai dengan sebagian besar data terkonsentrasi pada nilai yang rendah dan frekuensi yang semakin menurun pada nilai yang lebih tinggi. Kondisi ini menunjukkan bahwa mayoritas karyawan memiliki jarak rumah yang dekat dengan tempat kerja, pendapatan bulanan yang relatif rendah hingga sedang, pengalaman kerja dan masa kerja yang tidak terlalu lama, serta jumlah promosi dan pergantian perusahaan yang relatif sedikit, sedangkan hanya sebagian kecil karyawan yang memiliki nilai sangat tinggi pada variabel-variabel tersebut.





Gambar 5. Visualisasi Boxplot Variabel Numerik

Berdasarkan Gambar 5. Visualisasi Boxplot Variabel Numerik, terlihat bahwa sebagian besar variabel seperti *Age*, *DailyRate*, *DistanceFromHome*, *HourlyRate*, *MonthlyRate*, dan *PercentSalaryHike* tidak menunjukkan adanya outlier yang signifikan, sehingga distribusi datanya relatif stabil. Namun, beberapa variabel seperti *MonthlyIncome*, *TotalWorkingYears*, *YearsAtCompany*, *YearsInCurrentRole*, *YearsSinceLastPromotion*, *YearsWithCurrManager*, dan *NumCompaniesWorked* memiliki sejumlah titik yang berada di luar whisker boxplot, yang menunjukkan adanya outlier pada nilai tinggi. Kondisi ini mengindikasikan bahwa terdapat sebagian kecil karyawan dengan pendapatan, pengalaman kerja, masa kerja, atau riwayat pekerjaan yang jauh lebih tinggi dibandingkan mayoritas karyawan lainnya. Selain itu, variabel *MonthlyIncome* tampak memiliki sebaran yang cenderung menceng ke kanan (*right-skewed*), yang menunjukkan adanya perbedaan tingkat pendapatan yang cukup besar antar karyawan dalam dataset.



Gambar 6. Visualisasi Heatmap Korelasi antara Variabel Kategorik dan Numerik

Berdasarkan Gambar 6. Visualisasi Heatmap Korelasi antara Variabel Kategorik dan Numerik, terlihat bahwa sebagian besar pasangan variabel memiliki nilai eta-squared yang sangat kecil (mendekati 0), sehingga hubungan antara variabel kategorik dan numerik umumnya tergolong lemah. Namun, terdapat beberapa hubungan yang cukup kuat, terutama antara JobLevel dengan MonthlyIncome yang memiliki nilai korelasi sebesar 0,93, menunjukkan bahwa tingkat jabatan memiliki pengaruh yang sangat besar terhadap pendapatan bulanan karyawan. Selain itu, JobRole juga memiliki hubungan yang kuat dengan MonthlyIncome sebesar 0,82, yang mengindikasikan bahwa jenis pekerjaan turut memengaruhi tingkat pendapatan. Variabel TotalWorkingYears menunjukkan hubungan yang cukup kuat dengan JobLevel (0,63) dan hubungan sedang dengan JobRole (0,44), yang menandakan bahwa pengalaman kerja berkaitan dengan tingkat jabatan dan jenis pekerjaan yang dimiliki karyawan. Sementara itu, PerformanceRating memiliki hubungan yang cukup kuat dengan PercentSalaryHike sebesar 0,60, yang menunjukkan bahwa

penilaian kinerja berpengaruh terhadap persentase kenaikan gaji. Secara keseluruhan, heatmap ini menunjukkan bahwa JobLevel, JobRole, dan PerformanceRating merupakan variabel kategorik yang memiliki hubungan paling kuat dengan beberapa karakteristik numerik karyawan, khususnya pendapatan, pengalaman kerja, dan kenaikan gaji.

4.1.3 Identifikasi

Sebelum melakukan tahap analisis lebih lanjut, analisis pada tahap ini diperlukan beberapa identifikasi seperti identifikasi *missing value*, duplikasi data, *outlier*, dan ketidakseimbangan kelas.

1) Identifikasi *Missing Value*

Berdasarkan hasil analisis, dihasilkan jumlah *missing value* untuk seluruh variabel.

Tabel 4. Hasil Identifikasi Missing Value

Variabel	<i>Missing Value</i>
Age	0
Attrition	0
BusinessTravel	0
DailyRate	0
Department	0
DistanceFromHome	0
Education	0
EducationField	0
EmployeeCount	0
EmployeeNumber	0
EnvironmentSatisfaction	0

Gender	0
HourlyRate	0
JobInvolvement	0
JobLevel	0
JobRole	0
JobSatisfaction	0
MaritalStatus	0
MonthlyIncome	0
MonthlyRate	0
NumCompaniesWorked	0
Over18	0
OverTime	0
PercentSalaryHike	0
PerformanceRating	0
RelationshipSatisfaction	0
StandardHours	0
StockOptionLevel	0
TotalWorkingYears	0
TrainingTimesLastYear	0

WorkLifeBalance	0
YearsAtCompany	0
YearsInCurrentRole	0
YearsSinceLastPromotion	0
YearsWithCurrManager	0

Berdasarkan tabel tersebut, diketahui bahwa seluruh variabel dalam dataset memiliki nilai missing value sebesar 0. Hasil tersebut menunjukkan bahwa tidak terdapat data yang hilang pada seluruh 35 variabel yang digunakan dalam penelitian. Dengan demikian, dataset dapat dikatakan lengkap dan tidak memerlukan proses penanganan missing value seperti imputasi maupun penghapusan observasi.

Ketiadaan *missing value* menunjukkan bahwa kualitas data yang digunakan dalam penelitian cukup baik sehingga seluruh data dapat digunakan pada tahap analisis selanjutnya. Kondisi ini juga membantu mengurangi potensi bias yang dapat muncul akibat hilangnya informasi pada beberapa observasi. Oleh karena itu, proses pra-pemrosesan data dapat dilanjutkan ke tahap berikutnya tanpa perlu melakukan perlakuan khusus terkait data yang hilang.

2) Duplikasi Data

Data duplikat merupakan data yang memiliki nilai yang sama pada seluruh atribut sehingga menyebabkan adanya pengulangan observasi dalam dataset. Pemeriksaan data duplikat dilakukan untuk memastikan bahwa setiap observasi dalam dataset bersifat unik dan mewakili satu entitas yang berbeda. Hasil pemeriksaan menunjukkan bahwa tidak terdapat data duplikat dalam dataset yang digunakan pada penelitian ini.

Tabel 5. Hasil Identifikasi Duplikasi Data

Keterangan	Jumlah
Total Data	1470

Data Duplikat	0
Persentase Data Duplikat	0%

Berdasarkan hasil pemeriksaan, jumlah data duplikat yang ditemukan adalah 0 atau 0% dari total 1.470 observasi. Dengan demikian, tidak diperlukan proses penghapusan data duplikat dan seluruh data dapat digunakan pada tahap analisis berikutnya.


3) Outlier

Deteksi *outlier* dilakukan pada variabel numerik untuk mengetahui apakah terdapat nilai-nilai ekstrem yang berpotensi menyebabkan distribusi data menjadi tidak representatif. Pada penelitian ini, identifikasi outlier dilakukan menggunakan metode *Interquartile Range* (IQR). Metode ini mendeteksi outlier berdasarkan rentang data yang dibentuk oleh kuartil pertama (Q1) dan kuartil ketiga (Q3), sehingga data yang berada di luar batas bawah (*lower bound*) dan batas atas (*upper bound*) dapat diidentifikasi sebagai outlier.

Berdasarkan Gambar 4.2.3 terdapat *outlier* untuk beberapa variabel sehingga diperlukan penanganan untuk mengatasi permasalahan outlier tersebut.

4) Ketidakseimbangan Kelas

Sebelum dilakukan proses pemodelan, perlu dilakukan pemeriksaan terhadap distribusi kelas pada variabel target (*Attrition*). Tahap ini bertujuan untuk mengetahui apakah jumlah data pada masing-masing kelas berada dalam kondisi seimbang atau tidak. Ketidakseimbangan kelas (*class imbalance*) dapat mempengaruhi kinerja model klasifikasi karena model cenderung lebih mudah memprediksi kelas mayoritas dibandingkan kelas minoritas.



Gambar 7. Distribusi Variabel Attrition

Berdasarkan distribusi data pada variabel *Attrition*, diketahui bahwa kelas "No" memiliki jumlah sebanyak 1.233 observasi atau 83,88% dari total data, sedangkan kelas "Yes" berjumlah 237 observasi atau 16,12% dari total data. Perbedaan proporsi yang cukup besar antara kedua kelas menunjukkan bahwa dataset mengalami ketidakseimbangan kelas (*class imbalance*), di mana kelas "No" menjadi kelas mayoritas dan kelas "Yes" menjadi kelas minoritas.

Kondisi ketidakseimbangan kelas ini berpotensi menyebabkan model klasifikasi menghasilkan performa yang kurang optimal dalam mengidentifikasi karyawan yang mengalami *attrition*. Oleh karena itu, diperlukan teknik penanganan ketidakseimbangan data.

4.1.4 Temuan Awal

Berdasarkan hasil eksplorasi data awal, diperoleh beberapa informasi penting mengenai karakteristik data yang digunakan dalam penelitian. Dataset terdiri atas 1.470 data karyawan dengan 35 variabel yang mencakup variabel numerik dan kategorik. Hasil pemeriksaan kualitas data menunjukkan bahwa seluruh variabel tidak memiliki *missing value* maupun data duplikat, sehingga seluruh data dapat digunakan pada tahap analisis selanjutnya.

Berdasarkan statistik deskriptif variabel numerik, rata-rata usia karyawan adalah 36,92 tahun dengan rentang usia antara 18 hingga 60 tahun. Rata-rata pengalaman kerja karyawan (*TotalWorkingYears*) sebesar 11,28 tahun, sedangkan rata-rata masa kerja di perusahaan (*YearsAtCompany*) sebesar 7,01 tahun. Selain itu, variabel *WorkLifeBalance* memiliki nilai rata-rata sebesar 2,76 dan *EnvironmentSatisfaction* sebesar 2,72 pada skala 1 hingga 4, yang menunjukkan bahwa sebagian besar karyawan memiliki tingkat keseimbangan kehidupan kerja dan kepuasan lingkungan kerja pada kategori sedang hingga baik.

Sementara itu, hasil statistik deskriptif variabel kategorik menunjukkan bahwa mayoritas karyawan berasal dari departemen *Research & Development* sebanyak 961 karyawan, memiliki latar belakang pendidikan *Life Sciences* sebanyak 606 karyawan, berjenis kelamin laki-laki sebanyak 882 karyawan, serta berstatus menikah sebanyak 673 karyawan. Selain itu, sebagian besar karyawan tidak melakukan lembur (*OverTime*) dengan jumlah 1.054 karyawan.

Analisis distribusi variabel target *Attrition* menunjukkan adanya ketidakseimbangan kelas (*class imbalance*). Kelas "No" yang menunjukkan karyawan tidak keluar dari perusahaan berjumlah 1.233 data atau 83,88% dari total observasi, sedangkan kelas "Yes"

yang menunjukkan karyawan keluar dari perusahaan hanya berjumlah 237 data atau 16,12%. Perbedaan proporsi yang cukup besar antara kedua kelas tersebut mengindikasikan bahwa dataset didominasi oleh kelas mayoritas.

Temuan awal ini menunjukkan bahwa dataset memiliki kualitas data yang baik karena tidak ditemukan data hilang maupun data duplikat. Namun, terdapat ketidakseimbangan kelas pada variabel target yang berpotensi memengaruhi performa model klasifikasi. Oleh karena itu, diperlukan penanganan ketidakseimbangan data pada tahap pra-pemrosesan sebelum dilakukan proses pemodelan untuk memperoleh hasil klasifikasi yang lebih optimal.

4.2 Pra-Pemrosesan & Rekayasa Fitur

4.2.1 Penanganan *Missing Value*

Berdasarkan hasil pemeriksaan *missing value* pada Tabel 4, tidak ditemukan adanya nilai yang hilang pada seluruh variabel dalam dataset. Hal ini menunjukkan bahwa data yang digunakan telah lengkap dan memenuhi kebutuhan analisis. Dengan demikian, tidak diperlukan proses penanganan *missing value* seperti imputasi atau penghapusan data, sehingga seluruh data dapat langsung digunakan pada tahap pra-pemrosesan dan pemodelan berikutnya.

4.2.2 Penanganan *Outlier*

Berdasarkan hasil visualisasi boxplot pada Gambar 4.2.3, teridentifikasi beberapa observasi yang berada di luar batas *whisker* sehingga dikategorikan sebagai *outlier*. Keberadaan *outlier* tersebut berpotensi memengaruhi distribusi data dan menyebabkan bias pada proses pembentukan model. Oleh karena itu, dilakukan penanganan *outlier* menggunakan metode *Interquartile Range* (IQR). Metode ini bekerja dengan mengidentifikasi dan mengeliminasi data yang berada di luar rentang nilai yang ditentukan berdasarkan kuartil data. Setelah dilakukan penanganan menggunakan metode IQR, observasi ekstrem yang terdeteksi berhasil dihilangkan sehingga distribusi data menjadi lebih baik dan lebih representatif. Melalui proses penyaringan (*filtering*) tersebut, sebaran data berada dalam rentang nilai yang lebih wajar dan siap digunakan untuk tahapan analisis selanjutnya. Dengan berkurangnya pengaruh nilai-nilai ekstrem, kualitas data menjadi lebih optimal sehingga diharapkan dapat meningkatkan performa model machine learning yang dibangun.

4.2.3 Encoding Variabel Kategorik

Karena algoritma machine learning tidak dapat memproses data kategorik secara langsung, dilakukan proses *encoding* untuk mentransformasikan seluruh variabel kategorik menjadi representasi numerik. Pada tahap ini, variabel target *Attrition* dikonversi secara manual menjadi nilai biner, yaitu 1 untuk kategori *Yes* dan 0 untuk kategori *No*. Selanjutnya, variabel prediktor yang bertipe kategorik, baik yang bersifat ordinal maupun nominal, ditransformasikan menggunakan metode *Ordinal Encoding* melalui fungsi *OrdinalEncoder*. Proses ini bertujuan untuk mengubah data kategorik ke dalam bentuk numerik sehingga dapat diproses oleh algoritma machine learning. Selain itu, pendekatan ini dipilih karena mampu mempertahankan jumlah fitur yang ada tanpa menambah kolom baru (*feature expansion*), sehingga kompleksitas data dan kebutuhan komputasi tetap terjaga selama proses pelatihan model. Implementasi proses encoding dilakukan menggunakan pustaka Scikit-Learn dengan memanfaatkan *ColumnTransformer* untuk memastikan transformasi data berlangsung secara konsisten dan terstruktur pada seluruh variabel yang diproses. Hasil transformasi data dari bentuk kategorik menjadi numerik setelah proses encoding ditunjukkan pada Tabel 6.

Tabel 6. Encoding Variabel Kategorik

Variabel	Jenis Variabel	Data Asli (Kategorik)	Hasil Encoding (Numerik)
Attrition	Target Variable	"Yes"	1
		"No"	0
OverTime	Nominal	"Yes"	1.0
		"No"	0.0
		"Travel_Rarely"	2.0

Business Travel	Nominal		
		"Travel_Frequently"	1.0
		"Non-Travel"	0.0
JobSatisfaction	Ordinal	"Low"	0.0
		"Medium"	1.0
		"High"	2.0
		"Very High"	3.0

Berdasarkan hasil encoding yang ditampilkan pada Tabel ??, seluruh variabel kategorik telah berhasil dikonversi ke dalam bentuk numerik sehingga dapat digunakan pada tahapan normalisasi, pembagian data, dan pemodelan machine learning selanjutnya.

4.2.4 *Scaling* Fitur Numerik

Tahap *feature scaling* dilakukan untuk menyamakan skala antar variabel numerik sehingga setiap fitur memiliki kontribusi yang seimbang dalam proses pembentukan model. Proses ini penting karena beberapa variabel memiliki rentang nilai yang jauh lebih besar dibandingkan variabel lainnya. Sebagai contoh, variabel *MonthlyIncome* memiliki rentang nilai yang jauh lebih besar dibandingkan variabel *Age* atau *YearsAtCompany* sehingga berpotensi mendominasi proses pembelajaran model. Oleh karena itu, dilakukan normalisasi menggunakan metode *MinMaxScaler* untuk mentransformasikan seluruh fitur numerik ke

dalam rentang nilai 0 hingga 1. Hasil normalisasi menunjukkan bahwa seluruh fitur numerik telah berada pada skala yang lebih seragam sehingga siap digunakan pada tahap selanjutnya.

4.2.5 Standardisasi

Setelah proses normalisasi dilakukan, tahapan berikutnya adalah standardisasi data menggunakan metode *StandardScaler*. Metode ini bertujuan untuk menyesuaikan distribusi data sehingga memiliki nilai rata-rata (*mean*) mendekati 0 dan standar deviasi sebesar 1. Standardisasi dilakukan untuk mengurangi perbedaan distribusi antar fitur serta meningkatkan stabilitas proses pembelajaran model. Dengan distribusi data yang lebih seragam, model machine learning dapat mempelajari pola data dengan lebih optimal dan menghasilkan performa yang lebih baik. Hasil standardisasi menunjukkan bahwa seluruh fitur yang diproses telah berhasil ditransformasikan ke dalam skala yang lebih konsisten sehingga siap digunakan pada tahap pembagian data dan pemodelan.

4.2.6 Feature Engineering

Pada tahap feature engineering dilakukan penentuan variabel fitur dan variabel target yang akan digunakan dalam proses pemodelan. Variabel Attrition ditetapkan sebagai variabel target (Y), sedangkan seluruh variabel lainnya digunakan sebagai variabel fitur (X). Proses ini bertujuan untuk memastikan bahwa model machine learning dapat mempelajari hubungan antara karakteristik karyawan dan status attrition secara optimal. Berdasarkan hasil pemisahan data, diperoleh sebanyak 30 variabel fitur dan 1 variabel target yang selanjutnya digunakan pada tahap pembagian data dan pemodelan.

4.2.7 Train Test Split

Setelah proses pra-pemrosesan dan penentuan variabel fitur serta target selesai dilakukan, dataset dibagi menjadi data pelatihan (*training set*) dan data pengujian (*testing set*). Pembagian data dilakukan menggunakan metode *train-test split* dengan proporsi 80% untuk data pelatihan dan 20% untuk data pengujian. Tujuan dari pembagian ini adalah untuk melatih model menggunakan sebagian data dan mengevaluasi kinerjanya pada data yang belum pernah dilihat sebelumnya sehingga kemampuan generalisasi model dapat diukur secara objektif.

Berdasarkan hasil pembagian data, diperoleh sebanyak 895 observasi pada data pelatihan dan 224 observasi pada data pengujian. Selain itu, proses pembagian data dilakukan menggunakan parameter *stratify* untuk mempertahankan proporsi kelas pada variabel target Attrition. Dengan demikian, distribusi kelas pada data pelatihan dan data

pengujian tetap mencerminkan distribusi kelas pada dataset asli sehingga dapat mengurangi potensi bias selama proses pembentukan model.

Hasil pembagian data menunjukkan bahwa proporsi kelas pada data pelatihan terdiri atas 83,24% kelas *No* dan 16,76% kelas *Yes*, sedangkan pada data pengujian terdiri atas 83,04% kelas *No* dan 16,96% kelas *Yes*. Kesamaan proporsi tersebut menunjukkan bahwa proses *train-test split* berhasil mempertahankan karakteristik distribusi data sehingga data yang digunakan untuk pelatihan dan pengujian tetap representatif.


4.3 Pemodelan

Setelah seluruh tahapan pra-pemrosesan data selesai dilakukan, langkah berikutnya adalah membangun model machine learning untuk memprediksi status attrition karyawan. Namun, sebelum proses pelatihan model dilakukan, perlu dipastikan bahwa distribusi kelas pada variabel target berada dalam kondisi yang seimbang. Ketidakseimbangan kelas dapat menyebabkan model cenderung mempelajari pola dari kelas mayoritas sehingga menurunkan kemampuan model dalam mengenali kelas minoritas. Oleh karena itu, dilakukan proses penyeimbangan data (*balance data*) sebelum tahap pemodelan.

4.3.1 Balance Data

Berdasarkan hasil analisis eksplorasi data untuk distribusi variabel target *Attrition* menunjukkan adanya ketidakseimbangan kelas (*class imbalance*). Kelas "No" berjumlah 1.233 data atau 83,88% dari total observasi, sedangkan kelas "Yes" hanya berjumlah 237 data atau 16,12%. Ketidakseimbangan tersebut berpotensi menyebabkan model klasifikasi cenderung memprediksi kelas mayoritas dan mengabaikan pola pada kelas minoritas.

Untuk mengatasi permasalahan tersebut, dilakukan proses *Synthetic Minority Oversampling Technique* (SMOTE). Metode SMOTE digunakan untuk menyeimbangkan distribusi kelas dengan menghasilkan data sintetis pada kelas minoritas sehingga jumlah data antar kelas menjadi lebih proporsional.



Gambar 8. Hasil SMOTE Variabel Attrition

Berdasarkan hasil penerapan *Synthetic Minority Oversampling Technique* (SMOTE), distribusi kelas pada variabel target *Attrition* berhasil diseimbangkan. Sebelum dilakukan SMOTE, jumlah data pada kelas mayoritas (*No*) sebanyak 1.233 observasi, sedangkan kelas minoritas (*Yes*) hanya sebanyak 237 observasi. Setelah proses SMOTE diterapkan, jumlah observasi pada kedua kelas menjadi seimbang. Kondisi ini diharapkan dapat mengurangi bias model terhadap kelas mayoritas serta meningkatkan kemampuan model dalam mengidentifikasi dan mengklasifikasikan kelas minoritas secara lebih akurat.

4.3.2 Pemodelan

Pada penelitian ini digunakan tiga algoritma klasifikasi, yaitu *Logistic Regression*, *Random Forest*, dan *Extreme Gradient Boosting* (XGBoost). Ketiga algoritma tersebut dipilih karena memiliki karakteristik yang berbeda dalam melakukan klasifikasi sehingga dapat digunakan untuk membandingkan performa model dalam memprediksi kemungkinan terjadinya *Attrition*.

1) *Logistic Regression*

Pemodelan pertama menggunakan *Logistic Regression* yang akan diukur kemampuan model menggunakan beberapa metrik evaluasi, yaitu Accuracy, Precision, Recall, dan F1-Score. Selain itu, classification report digunakan untuk memberikan informasi yang lebih rinci mengenai performa model pada masing-masing kelas.

Tabel 7. Hasil Evaluasi Model Logistic Regression


Akurasi	Presisi	Recall	F1-score
0,7991	0,4444	0,7368	0,5545

Berdasarkan hasil pengujian, model Logistic Regression memperoleh nilai akurasi sebesar 0,7991 atau 79,91%. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan data dengan benar sebanyak 79,91% dari total data pengujian.

Nilai presisi sebesar 0,4444 atau 44,44% menunjukkan bahwa dari seluruh data yang diprediksi sebagai karyawan yang mengalami *attrition* (kelas 1), hanya 44,44% yang benar-benar mengalami *attrition*. Nilai precision yang relatif rendah mengindikasikan masih terdapat sejumlah prediksi positif yang salah (*false positive*).

Sementara itu, nilai recall sebesar 0,7368 atau 73,68% menunjukkan bahwa model mampu mengidentifikasi 73,68% karyawan yang benar-benar mengalami *attrition*. Nilai recall yang cukup tinggi mengindikasikan bahwa model memiliki kemampuan yang baik dalam mendeteksi karyawan yang berpotensi keluar dari perusahaan.

Nilai F1-Score sebesar 0,5545 atau 55,45% menunjukkan keseimbangan antara precision dan recall. Nilai ini mengindikasikan bahwa meskipun model cukup baik dalam menemukan karyawan yang mengalami *attrition*, tingkat ketepatan prediksi positif masih perlu ditingkatkan.



Gambar 9. Confusion Matrix Model Logistic Regression

Berdasarkan confusion matrix pada model Logistic Regression, diperoleh sebanyak 151 data yang berhasil diklasifikasikan dengan benar sebagai karyawan yang tidak mengalami *attrition* (*True Negative*) dan 28 data yang berhasil diklasifikasikan dengan benar sebagai karyawan yang mengalami *attrition* (*True Positive*).

Di sisi lain, terdapat 35 data yang sebenarnya tidak mengalami *attrition* tetapi diprediksi mengalami *attrition* (*False Positive*). Selain itu, terdapat 10 data yang sebenarnya mengalami *attrition* namun diprediksi tidak mengalami *attrition* (*False Negative*).

Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam mengidentifikasi karyawan yang tidak mengalami *attrition*. Selain itu, jumlah *False Negative* yang relatif rendah menunjukkan bahwa model mampu mendeteksi sebagian besar karyawan yang berpotensi keluar dari perusahaan. Dalam konteks prediksi *employee attrition*, kondisi ini penting karena kegagalan mendeteksi karyawan yang akan keluar dapat menyebabkan perusahaan kehilangan kesempatan untuk melakukan tindakan pencegahan.

2) Random Forest

Pemodelan kedua menggunakan *Random Forest* yang akan diukur kemampuan model menggunakan beberapa metrik evaluasi, yaitu Accuracy, Precision, Recall, dan F1-Score. Selain itu, classification report digunakan untuk memberikan informasi yang lebih rinci mengenai performa model pada masing-masing kelas.

Tabel 8. Hasil Evaluasi Model Random Forest

Akurasi	Presisi	Recall	F1-score
0,8839	0,8000	0,4211	0,5517


Berdasarkan hasil pengujian, model memperoleh nilai akurasi sebesar 88,39%. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan data dengan benar sebanyak 88,39% dari total data pengujian. Tingginya nilai akurasi mengindikasikan bahwa model memiliki kemampuan yang baik dalam membedakan karyawan yang mengalami *attrition* dan yang tidak mengalami *attrition*.

Nilai presisi sebesar 80,00% menunjukkan bahwa dari seluruh data yang diprediksi mengalami *attrition*, sebanyak 80,00% merupakan prediksi yang benar. Hasil ini

mengindikasikan bahwa model memiliki tingkat ketepatan yang cukup tinggi dalam memberikan prediksi positif sehingga jumlah prediksi positif yang salah relatif rendah.

Sementara itu, nilai recall sebesar 42,11% menunjukkan bahwa model hanya mampu mengidentifikasi 42,11% dari seluruh karyawan yang benar-benar mengalami *attrition*. Nilai recall yang relatif rendah mengindikasikan bahwa masih terdapat sejumlah karyawan yang mengalami *attrition* tetapi tidak berhasil terdeteksi oleh model.

Nilai F1-score sebesar 55,17% menunjukkan keseimbangan antara nilai presisi dan recall. Meskipun model memiliki tingkat presisi yang tinggi, rendahnya nilai recall menyebabkan nilai F1-score belum mencapai tingkat yang optimal.



Gambar 10. Confusion Matrix Model Random Forest

Berdasarkan Gambar 10, confusion matrix menunjukkan bahwa model Random Forest berhasil mengklasifikasikan 182 karyawan yang tidak mengalami *attrition* sebagai kelas *No Attrition* (True Negative) dan 16 karyawan yang mengalami *attrition* sebagai kelas *Attrition* (True Positive). Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengenali karyawan yang tidak mengalami *attrition*.

Selain itu, terdapat 4 karyawan yang sebenarnya tidak mengalami *attrition* tetapi diprediksi mengalami *attrition* (False Positive). Jumlah kesalahan ini relatif kecil, yang menunjukkan bahwa model memiliki tingkat ketepatan prediksi yang tinggi terhadap kelas positif. Namun, terdapat 22 karyawan yang sebenarnya mengalami *attrition* tetapi

diprediksi tidak mengalami *attrition* (False Negative). Jumlah *False Negative* yang cukup besar menunjukkan bahwa model masih mengalami kesulitan dalam mendeteksi seluruh karyawan yang berpotensi keluar dari perusahaan.

Hasil confusion matrix ini sejalan dengan nilai evaluasi model yang memperoleh akurasi sebesar 88,39% dan presisi sebesar 80,00%. Nilai tersebut menunjukkan bahwa model Random Forest mampu menghasilkan prediksi yang akurat dan memiliki tingkat ketepatan yang tinggi ketika memprediksi karyawan mengalami *attrition*. Akan tetapi, nilai recall sebesar 42,11% mengindikasikan bahwa model belum mampu mengidentifikasi seluruh karyawan yang benar-benar mengalami *attrition*.

3) *Extreme Gradient Boosting (XGBoost)*

Pemodelan ketiga menggunakan *Extreme Gradient Boosting (XGBoost)* yang akan diukur kemampuan model menggunakan beberapa metrik evaluasi, yaitu Accuracy, Precision, Recall, dan F1-Score. Selain itu, classification report digunakan untuk memberikan informasi yang lebih rinci mengenai performa model pada masing-masing kelas.


Tabel 9. Hasil Evaluasi Model Random Forest

Akurasi	Presisi	Recall	F1-score
0,8616	0,6207	0,4737	0,5373

Berdasarkan hasil evaluasi, model XGBoost memperoleh nilai akurasi sebesar 86,16%, yang menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data dengan benar. Nilai presisi sebesar 62,07% menunjukkan bahwa dari seluruh prediksi karyawan yang mengalami *attrition*, sebanyak 62,07% merupakan prediksi yang benar. Sementara itu, nilai recall sebesar 47,37% mengindikasikan bahwa model hanya mampu mengidentifikasi 47,37% dari seluruh karyawan yang benar-benar mengalami *attrition*.

Nilai F1-Score sebesar 53,73% menunjukkan keseimbangan antara nilai presisi dan recall. Berdasarkan classification report, model memiliki performa yang sangat baik pada kelas 0 (*No Attrition*) dengan nilai precision sebesar 0,90, recall sebesar 0,94, dan F1-score sebesar 0,92. Namun, pada kelas 1 (*Attrition*), model memperoleh precision sebesar 0,62, recall sebesar 0,47, dan F1-score sebesar 0,54, yang menunjukkan bahwa

kemampuan model dalam mendeteksi karyawan yang mengalami *attrition* masih perlu ditingkatkan.



Gambar 11. Confusion Matrix Model Extreme Gradient Boosting (XGBoost)

Berdasarkan Gambar 11, model XGBoost berhasil mengklasifikasikan 175 karyawan yang tidak mengalami *attrition* sebagai kelas *No Attrition* (True Negative) dan 18 karyawan yang mengalami *attrition* sebagai kelas *Attrition* (True Positive). Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam mengidentifikasi kedua kelas yang terdapat pada dataset.

Selain itu, terdapat 11 karyawan yang sebenarnya tidak mengalami *attrition* tetapi diprediksi mengalami *attrition* (False Positive). Sementara itu, terdapat 20 karyawan yang sebenarnya mengalami *attrition* tetapi diprediksi tidak mengalami *attrition* (False Negative). Jumlah *False Negative* yang masih cukup tinggi menunjukkan bahwa model belum mampu mendeteksi seluruh karyawan yang berpotensi keluar dari perusahaan.

4.3.3 Hyperparameter Tuning

Selain melakukan pemodelan selanjutnya dilakukan analisis *hyperparameter tuning* pada algoritma *logistic regression*.


Tabel 10. Hasil Evaluasi Model Hyperparameter Tuning Logistic Regression

Akurasi	Presisi	Recall	F1-score
0,7946	0,4394	0,7632	0,5577

Setelah dilakukan proses *hyperparameter tuning*, model Logistic Regression dievaluasi kembali menggunakan data pengujian untuk mengetahui peningkatan performa yang diperoleh. Hasil evaluasi menunjukkan bahwa model memperoleh nilai akurasi sebesar 79,46%, precision sebesar 43,94%, recall sebesar 76,32%, dan F1-score sebesar 55,77%.

Nilai akurasi sebesar 79,46% menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data pengujian dengan benar. Meskipun nilai akurasi mengalami sedikit penurunan dibandingkan model Logistic Regression sebelum tuning, model menunjukkan peningkatan pada kemampuan mendeteksi karyawan yang mengalami *attrition*.

Nilai recall sebesar 76,32% merupakan nilai tertinggi dibandingkan seluruh model yang diuji dalam penelitian ini. Hasil tersebut menunjukkan bahwa model mampu mengidentifikasi lebih dari tiga perempat karyawan yang benar-benar mengalami *attrition*. Dalam konteks prediksi *employee attrition*, kemampuan ini sangat penting karena perusahaan dapat lebih dini mengidentifikasi karyawan yang berpotensi keluar dan mengambil langkah pencegahan yang diperlukan.



Gambar 12. Confusion Matrix Model Hyperparameter Tuning Logistic Regression

Berdasarkan Gambar 12, confusion matrix menunjukkan bahwa model Tuned Logistic Regression berhasil mengklasifikasikan 149 karyawan yang tidak mengalami *attrition* sebagai kelas *No Attrition* (True Negative) dan 29 karyawan yang mengalami *attrition* sebagai kelas *Attrition* (True Positive).

Selain itu, terdapat 37 karyawan yang sebenarnya tidak mengalami *attrition* tetapi diprediksi mengalami *attrition* (False Positive). Sementara itu, terdapat 9 karyawan yang

sebenarnya mengalami *attrition* tetapi diprediksi tidak mengalami *attrition* (False Negative). Jumlah *False Negative* yang lebih rendah dibandingkan model Logistic Regression sebelum tuning menunjukkan bahwa proses tuning berhasil meningkatkan kemampuan model dalam mendeteksi karyawan yang berpotensi keluar dari perusahaan.

Hasil confusion matrix tersebut sejalan dengan nilai recall sebesar 76,32%, yang merupakan nilai recall tertinggi dibandingkan model lain yang diuji dalam penelitian ini. Nilai recall yang tinggi menunjukkan bahwa model mampu mengidentifikasi sebagian besar karyawan yang benar-benar mengalami *attrition*. Dalam konteks prediksi *employee attrition*, kemampuan ini sangat penting karena perusahaan dapat melakukan tindakan preventif terhadap karyawan yang berpotensi keluar.

4.4 Evaluasi

Setelah berhasil melakukan pemodelan diperlukan evaluasi yang baik untuk memilih pemodelan mana yang paling terbaik dalam mendeteksi karyawan yang mengalami *attrition*, sehingga evaluasi tersebut sebagai berikut.

Tabel 11. Hasil Evaluasi Semua Model

Model	Akurasi	Presisi	Recall	F1-Score
<i>Logistic Regression</i>	79,91%	44,44%	73,68%	55,45%
<i>Random Forest</i>	88,39%	80,00%	42,11%	55,17%
<i>XGBoost</i>	86,16%	62,07%	47,37%	53,73%
<i>Tuned Logistic Regression</i>	79,46%	43,94%	76,32%	55,77%

Berdasarkan hasil evaluasi dan perbandingan performa model, diperoleh bahwa Random Forest menghasilkan nilai accuracy dan precision tertinggi, masing-masing sebesar 88,39% dan 80,00%. Namun, model tersebut memiliki nilai recall yang relatif rendah, yaitu 42,11%, sehingga masih banyak kasus *attrition* yang tidak berhasil terdeteksi.

Sementara itu, *Tuned Logistic Regression* memperoleh nilai recall tertinggi sebesar 76,32% dan F1-Score tertinggi sebesar 55,77%. Hasil ini menunjukkan bahwa model

memiliki kemampuan yang lebih baik dalam mengidentifikasi karyawan yang berpotensi mengalami attrition dibandingkan model lainnya.

Karena tujuan utama penelitian adalah mendeteksi karyawan yang berpotensi keluar dari perusahaan, maka kemampuan model dalam mengidentifikasi kelas attrition menjadi aspek yang paling penting. Oleh karena itu, *Tuned Logistic Regression* dipilih sebagai model terbaik dalam penelitian ini karena mampu memberikan performa yang paling optimal dalam mendeteksi karyawan yang mengalami attrition.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil analisis terhadap IBM HR Analytics Employee Attrition & Performance Dataset menggunakan algoritma Logistic Regression, Random Forest, dan XGBoost, dapat disimpulkan bahwa faktor-faktor yang berkaitan dengan karakteristik karyawan, seperti usia, tingkat pendapatan, pengalaman kerja, masa kerja di perusahaan, tingkat jabatan, kepuasan kerja, lingkungan kerja, serta keseimbangan kehidupan dan pekerjaan memiliki peran penting dalam mempengaruhi terjadinya attrition karyawan. Hasil eksplorasi data juga menunjukkan bahwa dataset memiliki kualitas yang baik karena tidak ditemukan missing value maupun data duplikat, meskipun terdapat ketidakseimbangan kelas pada variabel target Attrition yang kemudian ditangani menggunakan metode SMOTE.

Hasil pemodelan menunjukkan bahwa ketiga algoritma mampu digunakan untuk mengklasifikasikan status attrition karyawan dengan tingkat performa yang berbeda. Model Random Forest menghasilkan nilai accuracy dan precision tertinggi, yaitu masing-masing sebesar 88,39% dan 80,00%, sehingga memiliki kemampuan yang baik dalam memberikan prediksi yang tepat. Namun, model ini memiliki nilai recall yang relatif rendah sebesar 42,11%, sehingga masih banyak kasus attrition yang tidak berhasil terdeteksi. Sementara itu, model XGBoost memperoleh performa yang cukup baik dengan accuracy sebesar 86,16% dan F1-score sebesar 53,73%.

Setelah dilakukan hyperparameter tuning pada Logistic Regression, diperoleh peningkatan kemampuan model dalam mendeteksi karyawan yang mengalami attrition. Tuned Logistic Regression menghasilkan nilai recall tertinggi sebesar 76,32% dan F1-score tertinggi sebesar 55,77%. Oleh karena itu, berdasarkan tujuan penelitian yang berfokus pada identifikasi karyawan yang berpotensi keluar dari perusahaan, Tuned Logistic Regression dipilih sebagai model terbaik karena mampu mendeteksi kasus attrition secara lebih optimal dibandingkan model lainnya. Hasil penelitian ini menunjukkan bahwa penerapan machine learning dapat menjadi alat yang efektif dalam mendukung pengambilan keputusan perusahaan untuk mengurangi risiko attrition dan meningkatkan strategi retensi karyawan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk penelitian selanjutnya. Pertama, penelitian berikutnya dapat menggunakan teknik feature selection yang lebih beragam atau menambahkan metode interpretasi model seperti SHAP (SHapley Additive Explanations) dan Feature Importance Analysis untuk memperoleh pemahaman yang lebih mendalam mengenai faktor-faktor yang paling berpengaruh terhadap attrition karyawan. Kedua, penelitian selanjutnya dapat mencoba algoritma machine learning lainnya, seperti LightGBM, CatBoost, Support Vector Machine, atau Neural Network untuk membandingkan performa model secara lebih komprehensif.

Selain itu, penelitian selanjutnya dapat menerapkan teknik penanganan ketidakseimbangan data yang berbeda, seperti ADASYN atau kombinasi SMOTE dan undersampling, guna meningkatkan kemampuan model dalam mendeteksi kelas minoritas. Penggunaan dataset yang lebih besar dan berasal dari berbagai perusahaan juga dapat dilakukan agar model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik. Dari sisi praktis, perusahaan disarankan untuk memanfaatkan hasil prediksi attrition sebagai sistem peringatan dini (early warning system) sehingga dapat melakukan tindakan preventif, seperti peningkatan kepuasan kerja, pengembangan karier, serta perbaikan keseimbangan kehidupan dan pekerjaan untuk mengurangi tingkat attrition karyawan.

LAMPIRAN

Link kode program :

<https://colab.research.google.com/drive/1tCAJKbPyZrXhyJbAXHumVbttgNlACQbw#scrollTo=VqFS0zsxC-sV>

Link dataset :

<https://www.kaggle.com/code/mohamedhazem346/ibm-employee-attrition-analysis/input>

Link github :

<https://github.com/faniahasna26/Project-Machine-Learning/tree/main>

Link ai :

<https://chatgpt.com/share/6a3beb28-9860-83ec-aaa0-88ed711de82c>