



////////

Analisis Attrition Karyawan Menggunakan Logistic Regression, Random Forest, dan XGBoost Menggunakan PYTHON

Disusun oleh :

1. Fania Hasna Rasyida K1D024001
2. Nabila Dwi Setiawati K1D024005
3. Kinanti Jingga Adzhani K1D024007
4. Amelia Wulandari K1D024027
5. Hafdsa Syafiya K1D024040



Pendahuluan


Permasalahan

- Attrition karyawan menyebabkan biaya rekrutmen dan pelatihan meningkat.
- Kehilangan karyawan berpengalaman dapat menurunkan produktivitas perusahaan.
- Perusahaan perlu mengidentifikasi karyawan yang berpotensi keluar lebih awal.

Solusi

- Memanfaatkan Machine Learning untuk memprediksi attrition karyawan berdasarkan karakteristik SDM.






Rumusan Masalah

1. Faktor-faktor apa saja yang memengaruhi attrition karyawan?
2. Bagaimana kinerja algoritma Logistic Regression, Random Forest, dan XGBoost dalam mengklasifikasikan attrition karyawan?
3. Algoritma manakah yang memberikan performa terbaik?

Tujuan

1. Mengidentifikasi faktor-faktor yang memengaruhi attrition karyawan.
2. Membangun model klasifikasi menggunakan Logistic Regression, Random Forest, dan XGBoost.
3. Membandingkan performa ketiga algoritma dan menentukan model terbaik.





Metodologi Penelitian



Data

Dataset IBM HR Analytics Employee Attrition & Performance

- Sumber: Kaggle
- 1.470 observasi dan 35 variabel
- Target: Attrition (Yes/No)

JS



CODE

CSS



Tahapan



- Data Understanding
- Data Preprocessing
- Feature Selection
- Data Splitting (80:20)
- Modeling (Logistic Regression, Random Forest, dan XGBoost)
- Evaluation (Accuracy, Precision, Recall, F1-Score)

Hasil

- Model terbaik prediksi Employee Attrition




Eksplorasi Data

• Statistika Deskriptif



- Terdapat 1470 karyawan dalam observasi ini dengan 35 variabel.
- Variabel Over18 seluruh bernilai Y, employeeCount seluruh bernilai 1, Standar Hours seluruh bernilai 80, artinya ketiga variabel tersebut konstan.
- Sebagian besar karyawan berada pada departemen *Research & Development*, dengan jenis kelamin laki-laki.
- Variabel Attrition memiliki 2 kategori dengan kategori yang paling dominan adalah No sebanyak 1.233 karyawan

• Heatmap




Heatmap korelasi antara Variabel Kategorik dan Numerik terlihat bahwa sebagian besar pasangan variabel memiliki nilai korelasi yang sangat kecil (mendekati 0), sehingga hubungan antara variabel kategorik dan numerik umumnya tergolong lemah.


Eksplorasi Data

• Identifikasi

- 1 Tidak terdapat missing value
- 2 Tidak terdapat duplikasi data
- 3 Terdapat Outlier
- 4 Terdapat ketidak seimbangan kelas



Diperlukan penanganan outlier dan Balancing data sebelum pemodelan



ALUR PREPROCESSING DATA


START:
DATA AWAL

Pemeriksaan Kualitas Data




1. Cek Missing Value (NIHIL)
2. Cek Data Duplikat (NIHIL)

Penanganan Outlier (IQR)




Identifikasi & Atasi Nilai
Ekstrem menggunakan
Interquartile Range (IQR)

Encoding Label




Transformasi Data Kategorik
menjadi Representasi
Numerik

Normalisasi & Standarisasi



Min-Max Scaling
(Normalisasi)



Z-Score
Standardization

Menyesuaikan Skala Fitur
agar Sebanding

Definisi Target & Fitur

TARGET: ATTRITION

YA ☒ TIDAK ☐

FITUR: 30 ATRIBUT INDEPENDEN



Penentuan Target dan
Seleksi 30 Fitur Relevan

Pemisahan Data (80:20 Split)



DATA
TESTING




Evaluative

Pembagian Proporsional untuk
Pemodelan & Evaluasi Terbuka

DATA SIAP
UNTUK
PEMODELAN




Pemodelan




• Balance Data

Before



Adanya ketidakseimbangan kelas pada variabel Attrition sehingga diperlukan penanganan imbalance data, seperti metode SMOTE

After



Data menjadi seimbang setelah dilakukan SMOTE. Dengan kelas target Yes dan No menjadi 984.



Pemodelan

1. Logistic Regression


Metrik Evaluasi

Akurasi	Presisi	Recall	F1-score
0,7991	0,4444	0,7368	0,5545

Model memiliki Recall yang lumayan tinggi. Artinya mampu menangkap sebagian besar kasus Attrition Yes. Namun, presisi masih rendah sehingga masih banyak False Positive.

Model memiliki performa yang cukup baik dengan akurasi 79%. Namun presisi yang rendah menunjukkan perlu perbaikan model untuk mengurangi False Positive

Confusion Matrix



- 151 data berhasil diklasifikasikan dengan benar sebagai karyawan yang tidak mengalami attrition (TN)
- 28 data berhasil diklasifikasikan dengan benar sebagai karyawan yang mengalami attrition (TP).
- 35 data yang sebenarnya tidak mengalami attrition tetapi diprediksi mengalami attrition (FP).
- 10 data yang sebenarnya mengalami attrition namun diprediksi tidak mengalami attrition (False Negative).



Pemodelan

2.Random Forest

Metrik Evaluasi


Akurasi	Presisi	Recall	F1-score
0,8839	0,8	0,4211	0,5517

Model memiliki Recall yang masih rendah (42,11%). Artinya model hanya mampu mendeteksi sekitar 42% karyawan yang benar-benar mengalami attrition. Yes. Namun, Presisi tinggi (80%), sehingga memprediksi attrition, hasilnya cukup dapat dipercaya

Model menghasilkan akurasi sebesar 88,39%, lebih tinggi dari Logistic Regression. Presisi mencapai 80%, yang menunjukkan bahwa sebagian besar prediksi attrition yang dihasilkan model memang benar terjadi. Namun recall hanya sebesar 42,11%, sehingga model masih belum optimal dalam menangkap seluruh kasus attrition



Confusion Matrix - Random Forest



- 182 data berhasil diklasifikasikan dengan benar sebagai karyawan yang tidak mengalami attrition (TN)
- 16 data berhasil diklasifikasikan dengan benar sebagai karyawan yang mengalami attrition (TP).
- 4 data yang sebenarnya tidak mengalami attrition tetapi diprediksi mengalami attrition (FP).
- 22 data yang sebenarnya mengalami attrition namun diprediksi tidak mengalami attrition (False Negative).

Pemodelan

3.XGBoost Klasifikasi

Metrik Evaluasi

Akurasi	Presisi	Recall	F1-score
0,8616	0,6207	0,4737	0,5373

Model memiliki Recall 47,37%, yang menunjukkan masih terdapat cukup banyak kasus attrition yang belum berhasil terdeteksi. Di sisi lain, Presisi sebesar 62,07% menunjukkan bahwa prediksi attrition yang dihasilkan model cukup akurat dan dapat diandalkan.

Model XGBoost menghasilkan akurasi 86,16%, yang menunjukkan klasifikasi yang cukup baik. Presisi 62,07% menunjukkan sebagian besar prediksi attrition sesuai dengan kondisi sebenarnya. Recall sebesar 47,37% mengindikasikan bahwa model masih belum mampu mendeteksi seluruh karyawan yang mengalami attrition.


Confusion Matrix - XGBoost

Actual \ Predicted	0	1
0	175 TN	11 FP
1	20 FN	18 TP

- 175 data berhasil diklasifikasikan dengan benar sebagai karyawan yang tidak mengalami attrition (TN)
- 18 data berhasil diklasifikasikan dengan benar sebagai karyawan yang mengalami attrition (TP).
- 11 data yang sebenarnya tidak mengalami attrition tetapi diprediksi mengalami attrition (FP).
- 20 data yang sebenarnya mengalami attrition namun diprediksi tidak mengalami attrition (False Negative).



Pemodelan




4.hyperparameter Tuning Logistic Regression

Metrik Evaluasi

Akurasi	Presisi	Recall	F1-score
0,7946	0,4394	0,7632	0,5577

Model memiliki Recall tinggi (76,32%), yang menunjukkan model mampu mendeteksi sekitar 76% karyawan yang benar-benar mengalami attrition. Namun, Presisi sebesar 43,94% menunjukkan bahwa prediksi attrition yang dihasilkan masih mengandung cukup banyak false positive, sehingga tidak semua karyawan yang diprediksi attrition benar-benar mengalami attrition.

Confusion Matrix - Tuned Logistic Regression



- 149 data berhasil diklasifikasikan dengan benar sebagai karyawan yang tidak mengalami attrition (TN)
- 29 data berhasil diklasifikasikan dengan benar sebagai karyawan yang mengalami attrition (TP).
- 37 data yang sebenarnya tidak mengalami attrition tetapi diprediksi mengalami attrition (FP).
- 9 data yang sebenarnya mengalami attrition namun diprediksi tidak mengalami attrition (False Negative).

Evaluasi

Model	Akurasi	Presisi	Recall	F1-Score
<i>Logistic Regression</i>	79,91%	44,44%	73,68%	55,45%
<i>Random Forest</i>	88,39%	80,00%	42,11%	55,17%
<i>XGBoost</i>	86,16%	62,07%	47,37%	53,73%
<i>Tuned Logistic Regression</i>	79,46%	43,94%	76,32%	55,77%

Tuned Logistic Regression memperoleh nilai recall tertinggi sebesar 76,32% dan F1-Score tertinggi sebesar 55,77%. Hasil ini menunjukkan bahwa model memiliki kemampuan yang lebih baik dalam mengidentifikasi karyawan yang berpotensi mengalami attrition dibandingkan model lainnya.




Kesimpulan

- Faktor-faktor seperti usia, pendapatan, pengalaman kerja, masa kerja, tingkat jabatan, kepuasan kerja, dan work-life balance berpengaruh terhadap attrition karyawan.
- Random Forest menghasilkan akurasi tertinggi (88,39%) dan precision tertinggi (80,00%).
- XGBoost menghasilkan performa yang cukup baik dengan akurasi 86,16% dan F1-score 53,73%.
- Tuned Logistic Regression menghasilkan recall tertinggi (76,32%) dan F1-score tertinggi (55,77%), sehingga menjadi model terbaik untuk mendeteksi karyawan yang berpotensi mengalami attrition.

Saran

- Perusahaan perlu memberikan perhatian lebih pada faktor-faktor yang berkaitan dengan kepuasan kerja, pendapatan, dan keseimbangan kehidupan kerja untuk mengurangi risiko attrition.
- Perusahaan dapat melakukan evaluasi dan pemantauan secara berkala terhadap karyawan yang teridentifikasi memiliki risiko attrition tinggi.
- Penelitian selanjutnya dapat menggunakan dataset dan metode yang lebih beragam untuk meningkatkan akurasi prediksi.



Terima Kasih

